

Análise de Fluxos e Resiliência do SUS via Teoria dos Grafos

Lucas Cardoso – RA 246125

Ricardo Andrade Oliveira Bello – RA 247326

MC859 – Entrega Final – 17 de junho de 2026

Repositório da implementação: <https://github.com/lcardosott/sus-graph-project>

Visualização interativa: lcardosott.github.io/sus-graph-project/viz_layer/graph_map_ui.html

Artefatos principais:

Relatório: [report/final_report.tex](#)

Visualização: [viz_layer/graph_map_ui.html](#)

Resultados: [algorithm_layer/reports/](#)

Resumo

Este trabalho modela internações e transferências hospitalares do SUS em 2021 como uma rede direcionada e ponderada. Os vértices representam municípios de residência e hospitais públicos; as arestas representam fluxos observados ou inferidos a partir dos registros do SIH/SUS. A análise combina construção de instâncias, filtros de recorrência e distância, centralidade de intermediação, comunidades Louvain, teste de supressão, k-caminhos e comparação com regiões oficiais de saúde. O principal resultado é que a rede pública hospitalar brasileira aparece conectada quando observada no agregado nacional, mas essa conectividade convive com dependências locais: fluxos recorrentes atravessam regiões oficiais, hospitais especializados atuam como polos estruturais e alguns municípios dependem de poucos destinos externos.

1 Introdução

O SUS pode ser observado como uma rede: pacientes residem em municípios, são internados em hospitais e, em alguns casos, continuam o atendimento em outro estabelecimento. Essa estrutura não é apenas administrativa; ela revela deslocamentos, polos de atração, redundâncias e gargalos. O objetivo do projeto foi transformar registros públicos de internação em um grafo analisável e usar algoritmos clássicos de grafos para investigar vulnerabilidades de acesso hospitalar.

A pergunta que guiou o trabalho foi: *a rede pública hospitalar observada nos dados é apenas conectada no agregado ou também oferece alternativas locais quando um município depende de poucos hospitais?* Para respondê-la, o projeto partiu do SIH/SUS 2021, integrou referências do CNES e do IBGE, construiu instâncias nacionais e avaliou tanto propriedades globais quanto padrões regionais.

O escopo inicial havia considerado um estudo estadual, mas a implementação final adotou Brasil 2021. A mudança aumentou a escala do grafo, permitiu comparar regiões com realidades distintas e atendeu melhor ao requisito de analisar redes grandes. O recorte final foi restringido a hospitais públicos/SUS, para que os resultados discutissem a rede pública de atendimento e não misturassem fluxos privados ou conveniados fora do escopo principal.

2 Dados e Pipeline

Foram usadas três famílias de dados públicos. O SIH/SUS fornece as Autorizações de Internação Hospitalar; o CNES identifica estabelecimentos, natureza pública/SUS e região de saúde; o IBGE fornece códigos territoriais e apoio geográfico [1, 3, 2]. A coleta e a preparação foram organizadas de forma modular: os scripts aceitam combinações de ano, meses e UFs, permitindo reproduzir a análise nacional ou gerar recortes menores para validação.

Tabela 1: Fontes de dados e artefatos derivados.

Fonte	Uso no projeto	Campos, referências e artefatos
SIH/SUS 2021	RD	CODMUNRES, CNES, IDADE, SEXO, RACA_COR, DIAG_PRINC, PROC_REA, DIAS_PERM, MARCA_UTI, VAL_TOT, óbito e sinais de transferência.
CNES		Identificação de hospitais públicos/SUS e regiões de saúde. Catálogo cnes_br_2101_public_hospitals.csv e campo REGSAUDE da competência 2101.
IBGE		Localização territorial. Códigos municipais, UFs e centróides usados quando não havia coordenada mais precisa para o estabelecimento.
Artefatos analíticos	Entrada dos algoritmos finais	data_layer/reports/analysis : painéis de hospitais, fluxos de residência, fluxos de transferência, nós e arestas enriquecidos.

O pipeline completo começa com a seleção dos arquivos SIH por ano, mês e UF em [sih_selector.py](#). A execução anual em [run_sih_year_pipeline.py](#) projeta colunas relevantes, valida contratos de esquema, cria arestas de residência, infere transferências e gera artefatos intermediários. A etapa final, [build_public_hospital_analysis.py](#), reutiliza

os Parquets curados de 2021 e cria as tabelas públicas analisadas pelos algoritmos. Assim, a reprodução da entrega final não exige baixar novamente os dados brutos quando os artefatos curados já existem.




Figura 1: Métricas exploratórias do grafo nacional de 2021: distribuição de graus e distribuição de tamanhos de componentes.




Figura 2: Amostra topológica do grafo gerado na etapa de modelagem. A visualização sem mapa evidencia a formação de agrupamentos densos e a presença de ligações entre blocos.

O grafo nacional original possui 11.823 nós e 203.184 arestas. No recorte final de hospitais públicos foram encontradas 11.629.005 linhas SIH reconciliadas, 5.875 hospitais públicos presentes no grafo, 188.035 arestas no escopo público, 181.569 fluxos município $\rightarrow$ hospital e 6.466 fluxos hospital $\rightarrow$ hospital. Outros 377 estabelecimentos fora do escopo público foram preservados como controle de qualidade, mas excluídos das conclusões finais.

3 Construção das Instâncias

O grafo final é dirigido e ponderado: $G = (V, E, w, d)$. O conjunto V contém dois tipos de vértices: municípios e hospitais públicos. Uma aresta de residência $u \rightarrow v$ liga o município de residência do paciente ao hospital de internação; uma aresta de transferência $h_i \rightarrow h_j$ liga dois hospitais quando os registros indicam continuidade provável de atendimento. O peso $w(e)$ representa volume agregado e $d(e)$ representa distância geográfica aproximada.

Modelagem do grafo assistencial





Figura 3: Modelagem do grafo assistencial: municípios e hospitais formam nós de naturezas distintas, ligados por fluxos de residência e por transferências hospitalares inferidas.

As transferências exigiram maior cuidado porque a base não oferece, de forma limpa e universal, uma lista explícita de origem e destino. A implementação adotou uma heurística conservadora de quatro pilares em `transfer_matching.py`: sinal de transferência por campo ou motivo de saída validado, janela temporal de 24 a 48 horas entre alta e nova internação, continuidade demográfica por sexo e idade, e continuidade clínica por capítulo CID-10. O CID-10 é a Classificação Internacional de Doenças, usada nos registros hospitalares para codificar diagnósticos; neste trabalho, ele foi usado apenas de forma agregada para verificar se a internação seguinte parecia pertencer ao mesmo quadro clínico. Quando havia múltiplos candidatos, a escolha priorizava menor intervalo temporal, CID exato e identificador de destino estável. Esse procedimento não deve ser lido como rastreamento individual perfeito, mas como uma forma reprodutível de inferir relações estruturais recorrentes entre hospitais.

Heurística de pareamento de transferências



Resultado: aresta dirigida $h_i \rightarrow h_j$ ponderada pelo número de transferências recorrentes.

Figura 4: Heurística de pareamento usada para inferir transferências: o vínculo entre hospitais combina sinal administrativo, janela temporal e continuidade demográfica e clínica.

A distância entre os pontos foi calculada pela fórmula de Haversine:

$$d = 2r \arcsin \sqrt{\sin^2 \left(\frac{\Delta\phi}{2} \right) + \cos(\phi_1) \cos(\phi_2) \sin^2 \left(\frac{\Delta\lambda}{2} \right)}, \quad (1)$$

em que ϕ é latitude, λ é longitude e r é o raio aproximado da Terra. Quando a coordenada exata do hospital não estava disponível, foi usado o centróide do município. Essa decisão aumenta a cobertura nacional, mas limita interpretações

finas dentro de cidades grandes.

Para reduzir ruído, as instâncias algorítmicas usaram dois filtros. O primeiro é de recorrência: fluxos residência → hospital entram com pelo menos 5 ocorrências e transferências hospital → hospital com pelo menos 2 ocorrências. O segundo é de distância mínima: foram geradas instâncias de 25 km e 50 km. O corte de 25 km captura fricções regionais e locais que já podem ser relevantes para pacientes; o corte de 50 km é mais seletivo e destaca dependências mais longas. Esses cortes não são percentuais da base: são limiares geográficos aplicados às arestas depois da agregação.

Listing 1: Construção da instância analítica filtrada.

```
para cada aresta e do grafo publico:
    se e.tipo = residencia e e.volume < 5: descartar
    se e.tipo = transferencia e e.volume < 2: descartar
    se e.distancia_km < distancia_minima: descartar
    manter e na instancia

G_dir = grafo dirigido com as arestas mantidas
G_proj = projecao nao dirigida ponderada por volume e distancia
usar maior componente de G_proj para centralidade, comunidades e stress test
```

4 Implementação

A implementação foi dividida em camadas para manter rastreabilidade e facilitar reexecuções parciais. A `data_layer` concentra coleta, validação e tabelas analíticas; a `model_layer` constrói o grafo anual em GEXF; a `filter_engine` implementa filtros reutilizáveis de distância, tipo e recorrência; a `algorithm_layer` executa os métodos finais; a `viz_layer` produz mapas, figuras e uma visualização interativa leve.

Os algoritmos finais estão em `public_hospital_analysis.py` e `regional_flow_analysis.py`. Para centralidade, comunidades, k-caminhos e supressão foi usada uma projeção não direcionada ponderada da maior componente. A direção original é essencial para construir os fluxos, mas a projeção torna a análise de conectividade assistencial mais adequada: em um grafo estritamente dirigido, muitos caminhos município → hospital não retornam e as medidas ficariam dominadas pela orientação administrativa das arestas.

Tabela 2: Arquivos de implementação e saídas principais dos algoritmos.

Método	Implementação	Saídas principais
Centralidade de intermediação	<code>public_hospital_analysis.py</code>	<code>centrality.csv</code> e <code>summary.json</code> .
Comunidades Louvain	<code>public_hospital_analysis.py</code>	<code>communities.csv</code> e <code>community_region_overlap.csv</code> .
Supressão dinâmica	<code>public_hospital_analysis.py</code>	<code>stress_dynamic.csv</code> e <code>sensitivity_matrix.csv</code> .
K-caminhos mais curtos	<code>public_hospital_analysis.py</code>	<code>k_path_redundancy.csv</code> .
Fluxo máximo/corte mínimo	<code>public_hospital_analysis.py</code>	<code>min_cut_capacity.csv</code> e <code>min_cut_facilities.csv</code> .
Regiões de saúde	<code>regional_flow_analysis.py</code>	<code>regional_overall.csv</code> , <code>regional_mismatch.csv</code> e <code>municipality_dependency.csv</code> .

Do grafo dirigido à projeção não dirigida ponderada




Figura 5: Passagem do grafo dirigido de fluxos para a projeção não dirigida ponderada usada pelos algoritmos de conectividade.

A validação combinou testes automatizados e reconciliação de totais. Os testes cobrem seleção SIH, contratos de esquema, enriquecimento de nós, filtros, construção do recorte público e algoritmos. Além disso, os totais do grafo,

das tabelas públicas e dos relatórios finais foram comparados por arquivos de resumo JSON. Essa estratégia não elimina limitações dos dados públicos, mas torna as transformações auditáveis.

5 Algoritmos e Resultados

5.1 Centralidade de Intermediação

A centralidade de intermediação (*betweenness centrality*) mede quanto um vértice aparece em caminhos mínimos entre outros pares de vértices. No contexto do projeto, um hospital com alta intermediação não é apenas um hospital com grande volume; ele atua como ponte entre municípios, regiões e corredores de atendimento. A distância foi usada como custo dos caminhos, e a métrica foi aproximada por amostragem para viabilizar a execução em máquina local.

Listing 2: Centralidade de intermediação em hospitais públicos.

```
G = maior componente da projecao ponderada
calcular betweenness em G usando distancia_km como custo
selecionar apenas vertices do tipo hospital
ordenar hospitais por betweenness decrescente
```




Figura 6: Distribuição espacial dos hospitais de maior intermediação no corte de 50 km, sobreposta a uma amostra dos corredores filtrados.




Figura 7: Hospitais públicos com maior centralidade de intermediação nas instâncias finais.

No corte de 50 km, os principais hospitais por centralidade foram Fundação Pio XII Barretos, Hospital Amaral Carvalho Jaú, Hospital São Vicente de Paulo, Hospital Regional Tibério Nunes, Hospital Municipal Esaú Matos, Hospital das Clínicas FAEPA Ribeirão Preto e Hospital de Base de São José do Rio Preto. O resultado é coerente com hospitais especializados, universitários e regionais, que funcionam como referência para múltiplas origens. A centralidade, portanto, reforça a ideia de polos estruturais: alguns hospitais organizam fluxos em escala superior ao município onde estão localizados.

5.2 Comunidades Louvain

O método Louvain agrupa vértices que têm conexões internas mais fortes do que conexões com o restante da rede. A métrica otimizada é a modularidade; no projeto, o peso das arestas foi o volume agregado. As comunidades não foram tratadas como regiões oficiais, mas como regiões funcionais sugeridas pelos próprios fluxos.

Comunidades Louvain e modularidade

Comunidades indicam blocos funcionais de circulação hospitalar.




Figura 8: Intuição do Louvain: comunidades concentram muitas arestas internas e poucas arestas entre grupos, maximizando modularidade.

As instâncias principais tiveram 49 comunidades no corte de 25 km e 43 comunidades no corte de 50 km. A redução ocorre porque o corte de 50 km remove parte dos deslocamentos regionais curtos e deixa uma rede mais seletiva, concentrada em corredores longos. A comparação com UFs e regiões de saúde foi usada como evidência de alinhamento ou desalinhamento entre a rede funcional e a divisão administrativa.





Figura 9: Maiores comunidades Louvain no corte de 50 km, separando municípios e hospitais. Comunidades maiores misturam muitos municípios de origem com um conjunto menor de hospitais de referência.

5.3 Supressão Dinâmica

O teste de supressão remove iterativamente hospitais com maior intermediação e recalcula a maior componente e o caminho médio amostrado. A pergunta não é se a rede “deixa de existir”, mas se a retirada de polos centrais alonga caminhos ou fragmenta a conectividade.

Stress test por remoção dinâmica



a remoção de um polo pode fragmentar caminhos ou alongar rotas alternativas

Figura 10: Procedimento do teste de supressão dinâmica: recalculando intermediação, remover um polo e medir o efeito sobre conectividade e rotas.

Listing 3: Teste de supressão dinâmica.

```

G = maior componente da instancia filtrada
registrar tamanho da componente e caminho medio amostrado
para passo em 1..5:
  recalculando betweenness dos hospitais em G
  remover hospital com maior betweenness
  recalculando maior componente e caminho medio amostrado
  
```




Figura 11: Efeito da supressão de hospitais centrais sobre maior componente e caminho médio amostrado.

Tabela 3: Resumo das instâncias e do stress test após cinco remoções.

Instância	Nós	Arestas	Comunidades	Maior comp. final	Aumento caminho
25 km	8.622	61.706	49	99,9072%	0,7839%
50 km	7.750	47.739	43	99,4702%	1,2597%

O resultado agregado indica que a rede nacional não se fragmenta facilmente. Porém, essa conclusão precisa ser lida com cuidado: conectividade nacional não mede disponibilidade de vaga, tempo real de deslocamento ou impacto local. A rede pode preservar 99% da maior componente enquanto um município específico perde seu destino de referência. Por isso, o stress test é mais útil como contraste: ele mostra robustez global, e essa robustez torna ainda mais necessário olhar dependências municipais.

5.4 K-Caminhos Mais Curtos

Os k -caminhos mais curtos (*k-shortest paths*) foram usados para avaliar redundância. Em vez de perguntar apenas qual é o menor caminho entre uma origem e um hospital, o método pergunta quais seriam as próximas melhores alternativas. Assim, para um par município $\rightarrow$ hospital de alto volume, calculamos o melhor caminho k_1 e, quando existente, um segundo caminho k_2 que não repete exatamente a mesma rota. A razão $d(k_2)/d(k_1)$ indica o custo relativo da alternativa.

Essa leitura é importante porque conectividade não significa substituição fácil. Se k_2 tem distância parecida com k_1 , há alguma redundância prática. Se k_2 é duas, três ou cinco vezes mais longo, a rede até possui uma alternativa topológica, mas ela pode ser ruim como opção assistencial. Quando apenas um caminho foi encontrado na instância filtrada, o par foi marcado como sem alternativa relevante dentro dos critérios de recorrência e distância adotados.

No corte de 50 km, entre os pares analisados, houve casos com três caminhos encontrados, mas com segunda alternativa acima de duas vezes a distância do melhor caminho. Também houve pares com apenas um caminho relevante dentro da instância filtrada. Isso mostra que redundância não é binária: uma região pode estar conectada no grafo e ainda assim depender de alternativas longas ou frágeis.




Figura 12: Razão entre o segundo e o primeiro caminho mais curto em pares de alto volume no corte de 50 km. Valores acima de 2 indicam alternativas formalmente existentes, mas possivelmente pouco substitutivas.

5.5 Fluxo Máximo e Corte Mínimo

O projeto incluiu uma aproximação de fluxo máximo/corte mínimo, mas ela foi rebaixada para resultado exploratório. O teorema max-flow/min-cut é adequado para estudar gargalos quando há capacidades confiáveis nas arestas e nos destinos. Neste trabalho, a capacidade disponível foi aproximada pelo volume anual observado, que não equivale a leitos operacionais, equipe, ocupação simultânea, especialidade ou disponibilidade temporal. Assim, a implementação fica no repositório como base para continuidade, mas as conclusões finais não dependem dela.

6 Regiões Oficiais e Dependência Municipal

A comparação regional usou o campo REGSAUDE dos arquivos CNES/ST de janeiro de 2021. A referência cobriu 27 arquivos estaduais, 334.702 linhas CNES e 5.570 municípios, mas também registrou 1.250 municípios com conflito de código regional entre estabelecimentos e 239 sem região identificada. Por isso, a regionalização foi tratada como aproximação oficial baseada no CNES, não como verdade administrativa perfeita.

Tabela 4: Fluxos recorrentes que cruzam região oficial de saúde.

Distância	Tipo	Arestas	Fluxo total	Fora da região	Parcela fora	Dist. média pond.
25 km	Residência	60.646	3.488.440	1.117.796	32,04%	86,96 km
25 km	Transferência	1.060	3.585	1.868	52,11%	148,14 km
50 km	Residência	46.938	1.942.302	850.778	43,80%	128,20 km
50 km	Transferência	801	2.748	1.676	60,99%	182,08 km

A Tabela 4 concentra um dos achados centrais. Aqui, “fora da região” não significa necessariamente sair do estado. A comparação usa a região oficial de saúde do CNES, identificada pelo campo REGSAUDE; um mesmo estado possui várias regiões de saúde, por isso muitos cruzamentos aparecem como PE-0004 → PE-0001, SP-0201 → SP-0101 ou BA-0003 → BA-0001. Esses são fluxos entre regiões administrativas diferentes dentro da mesma UF. Cruzamentos de estado também existem e foram calculados separadamente como *cross UF*, mas não são o foco desta tabela.

Quando os fluxos são recorrentes, parte expressiva do atendimento ultrapassa a região oficial de saúde. Isso não significa que todo deslocamento inter-regional seja problemático: alta complexidade frequentemente exige referência externa. O sinal de vulnerabilidade aparece quando o deslocamento é repetido, longo e concentrado em poucos destinos.




Figura 13: Parcela do fluxo recorrente que cruza regiões oficiais de saúde, por tipo de aresta e limiar de distância.




Figura 14: Principais corredores região → região no corte de 50 km. A anotação ao lado das barras indica também a participação do corredor no fluxo de origem.

Tabela 5: Exemplos de dependência municipal no corte de 50 km.

Município	Principal destino externo	Fluxo	Participação	Distância
Serra Nova Dourada – MT	Hospital Regional de Água Boa	96	100%	241,2 km
Caiana – MG	Hospital do Câncer de Muriaé	70	100%	65,4 km
Dom Cavati – MG	Hospital Municipal Eliane Martins	58	100%	50,1 km
Bujaru – PA	Hospital Regional Público Dr. Abelardo Santos	47	100%	56,1 km
Santana do Cariri – CE	Hospital Maternidade São Vicente de Paulo	41	100%	50,8 km

Esses exemplos mostram por que a média nacional é insuficiente. Para a rede inteira, uma remoção pode alterar pouco a maior componente; para um município que concentra 100% do fluxo filtrado em um destino fora de sua região, a perda desse destino representa uma fragilidade concreta. Em um estudo mais focalizado, uma extensão natural seria escolher um estado ou macrorregião, validar a regionalização com bases locais e analisar impactos percentuais por município e especialidade.

7 Visualização

A visualização final foi desenhada como camada de apresentação analítica, não como tentativa de renderizar todas as 188 mil arestas no navegador. O script `build_final_map_layers.py` gera o arquivo leve `final_map_layers.json`, com corredores principais, hospitais centrais, nós removidos no stress test, comunidades e exemplos de dependência municipal.

No `graph_map_ui.html`, o usuário pode alternar presets de 25 km, 50 km, hospitais centrais, stress test e dependência municipal. A interface evita desenhar tudo ao mesmo tempo: trabalha com camadas reduzidas, oculta arestas durante navegação e redesenha em blocos. Essa decisão foi necessária porque a visualização bruta ficava pesada, enquanto a versão guiada preserva a mensagem analítica e roda em computadores comuns. Como alternativa estática, `final_showcase.html` reúne gráficos e tabelas principais.




Figura 15: Amostras estáticas dos presets de 25 km e 50 km da camada final: o corte de 25 km preserva mais fricções regionais, enquanto 50 km destaca corredores longos e seletivos.




Figura 16: Exemplos geográficos de dependência municipal usados pela camada de visualização final.

8 Limitações e Interpretação

Os resultados devem ser interpretados como análise de acesso realizado, não de necessidade total. O SIH mostra internações que ocorreram; ele não mostra pacientes que não conseguiram vaga, demanda reprimida ou tempo de

espera. Além disso, a base anual não mede capacidade simultânea: volume em 2021 não informa quantos leitos estavam disponíveis em uma semana crítica, quais equipes estavam ativas ou quais especialidades eram necessárias. Outra limitação é espacial. A distância Haversine aproxima deslocamento em linha geodésica, mas não mede tempo por estrada, transporte público, rios ou barreiras locais. Em áreas rurais e amazônicas, 50 km podem representar realidades muito diferentes. A inferência de transferências também é probabilística e conservadora; ela é útil para padrões estruturais, mas não substitui uma base clínica de regulação com identificadores explícitos de origem e destino. Por fim, a análise regional depende do REGSAUDE disponível no CNES/ST. Como foram encontrados conflitos e ausências, a comparação com regiões oficiais é uma aproximação. Ainda assim, o volume de fluxos fora da região é suficientemente alto para indicar uma tensão real entre o desenho administrativo e os caminhos observados nos dados.

9 Conclusão

O projeto transformou dados públicos de internação em uma rede nacional documentada, filtrável, analisável e visualizável. A implementação entregou não apenas o grafo, mas também camadas de validação, tabelas analíticas, algoritmos e uma interface final para explorar os resultados.

A conclusão substantiva é que a rede pública hospitalar brasileira de 2021 é conectada no agregado, mas não homogênea. Hospitais especializados e regionais aparecem como polos estruturais; fluxos recorrentes cruzam regiões oficiais de saúde; e alguns municípios dependem fortemente de poucos destinos externos. Portanto, a contribuição do trabalho não é apenas apontar hospitais grandes, mas mostrar como a estrutura dos fluxos revela dependências locais que métricas nacionais podem esconder.

Como continuidade, o projeto ganharia precisão com leitos por competência, ocupação temporal, tempo real de deslocamento, separação por especialidade e validação regional com dados locais. Um estudo focalizado em um estado de referência também permitiria medir impactos percentuais com mais sensibilidade e discutir políticas de regionalização com bases administrativas mais limpas.

Referências

- [1] DATASUS. Sistema de informacoes hospitalares do sus - sih/sus, 2026. Acesso em 2026-06-10.
- [2] IBGE. Api de localidades, 2026. Acesso em 2026-06-10.
- [3] Ministerio da Saude. Cadastro nacional de estabelecimentos de saude - cnes, 2026. Acesso em 2026-06-10.